

Tahapan Sentimen Analisis

1. Scraping data

Scraping data dilakukan dengan Chrome extensions dan secara manual untuk mempercepat pengambilan data. Terdapat dua extensions sejenis, yaitu [IG Exporter & Scraper](#) dan [SocialDeck](#). Untuk melakukan scraping, pengguna hanya perlu memasukan link post saja, tetapi Instagram sudah harus login di Chrome.

Instagram dapat mendeteksi adanya bot scraping, yang dapat mengakibatkan akun Instagram ditangguhkan. Chrome extensions yang digunakan cukup aman, tetapi tidak sepenuhnya menghilangkan resiko penangguhan akun.

2. Cleaning data

Setelah data diambil dan dikumpulkan pada satu file, dilakukan pembersihan awal terhadap komentar dengan kondisi tertentu.

- *Replies* terhadap komentar akun lain
Dilakukan dengan menghapus komentar yang me-mention akun lain. Hal ini dilakukan karena replies tersebut bereaksi terhadap komentar bukan post.
- Komentar dari pemilik akun yang dianalisis / pemilik post.
- Komentar yang hanya berisi angka atau emoji
- Komentar spam, terutama yang mempromosikan obat dan judi online.

3. Preprocessing data

Untuk mendapatkan hasil prediksi yang lebih baik, dilakukan beberapa teknik preprocessing pada data komentar yang masih kotor.

- Casefolding (mengubah seluruh data menjadi huruf kecil).
- Menghapus mentions, hashtag, dan link.
- Menambahkan spasi pada angka dan kata yang menempel (misal: 100rb, 2jt)
- Mengubah angka menjadi kata. (misal: 2 jt -> dua juta)
- Mengubah kata dengan pemanjangan (penambahan huruf).
- Mengubah slang dan singkatan menjadi kata baku
- Menghapus emoji, whitespace, dan karakter bahasa lain.
- Menerjemahkan sebagian kata bahasa Inggris ke bahasa Indonesia.

4. Prediksi sentimen dengan IndoBERT

BERT adalah model deep learning ciptaan Google yang telah dilatih dengan jutaan artikel Wikipedia dan kamus bahasa Inggris, sehingga memungkinkan model ini untuk

memahami konteks dan tata bahasa pada kalimat. Banyak penelitian sebelumnya yang sudah melatih model ini agar bisa memahami bahasa Indonesia, salah satunya adalah indobERTweet. Model ini sudah dilatih dengan data tweets bahasa Indonesia.

Supaya dapat melakukan klasifikasi sentimen, model perlu dilatih kembali dengan dataset yang sudah diberi label. Karena keterbatasan waktu, pada percobaan ini digunakan model yang sudah tersedia pada platform Hugging Face, yaitu model dari [rikidharmawan/finetuning-sentiment-model-indobertweet-v2](https://huggingface.co/rikidharmawan/finetuning-sentiment-model-indobertweet-v2).

5. Persentase komentar minta-minta

Sebagian akun Instagram yang dianalisis seringkali menampilkan kekayaannya baik dengan memperlihatkan kegiatan mereka atau dengan membuat konten dimana mereka membagikan sejumlah uang atau barang. Hal ini membuat komentar dari postingan mereka berisi orang-orang yang juga berharap diberi oleh mereka.

Untuk menghitung persentase komentar tersebut, maka dicari beberapa kata kunci dari komentar yang sudah melalui Preprocessing. Kata dan frasa yang digunakan antara lain, juta, iphone, bagi dong, android, thr, angpao, minta uang, dan transfer.

6. Wordcloud

Untuk melihat kata-kata yang sering muncul pada komentar dari masing-masing Influencer, dapat digunakan wordcloud. Pada wordcloud, semakin besar ukuran kata berarti kata tersebut semakin sering muncul. Untuk setiap akun, pembuatan wordcloud dibagi berdasarkan tahunnya. Hal ini dilakukan agar perubahan konten, sentimen, dan jenis komentar dapat terlihat juga.

<https://indolem.github.io/IndoBERT/>

<https://huggingface.co/indolem/indobertweet-base-uncased>